

Giovanni Amorim

1. Questão 3 da prova.

(a) $\bar{g}(x) = E_D(g^{(D)}(x))$

O modelo linear se "encaixa" nos dois pontos, formando a reta que os contém:

$$y = mx + k$$

$$m = \frac{y_1 - y_2}{x_1 - x_2}$$

$$y_1 = \frac{y_1 - y_2}{x_1 - x_2} x_1 + k$$

$$k = y_1 - \frac{y_1 - y_2}{x_1 - x_2} x_1$$

$$k = \frac{x_1 y_2 - y_1 x_2}{x_1 - x_2}$$

Logo:

$$g^{(D)}(x) = \frac{y_1 - y_2}{x_1 - x_2} x + \frac{x_1 y_2 - y_1 x_2}{x_1 - x_2}$$

$$\bar{g}(x) = E_D\left[\frac{y_1 - y_2}{x_1 - x_2} x + \frac{x_1 y_2 - x_2 y_1}{x_1 - x_2}\right]$$

$$g^{(D)}(x) = \left(\frac{1}{2}\right)^2 \int_{-1}^1 \int_{-1}^1 \frac{x_1^2 - x_2^2}{x_1 - x_2} x dx_1 dx_2 + \left(\frac{1}{2}\right)^2 \int_{-1}^1 \int_{-1}^1 \frac{x_1 x_2^2 - x_2 x_1^2}{x_1 - x_2} dx_1 dx_2$$

$$g^{(D)}(x) = \frac{1}{4} \int_{-1}^1 \int_{-1}^1 [(x_1 + x_2)x + x_1 x_2] dx_1 dx_2$$

$$g^{(D)}(x) = 0.x + 0 = 0$$

(b) $E_{out} = E_x[(g(x) - f(x))^2]$

Considerando

$$g(x) = mx + k$$

:

$$E_{out} = E_x[(mx + k - x^2)^2]$$

$$E_{out} = E_x(x^4) - 2kE_x(x^3) + (k^2 - 2m)E_x(x^2) + 2kmE_x(x) + m^2$$

$$E_{out} = \frac{1}{2} \int_{-1}^1 x^4 dx - 2m \frac{1}{2} \int_{-1}^1 x^3 dx + (m^2 - 2k) \frac{1}{2} \int_{-1}^1 x^2 dx + 2mk \frac{1}{2} \int_{-1}^1 x dx + k^2$$

$$E_{out} = \frac{1}{2} \cdot \frac{2}{5} - m \cdot \frac{0}{4} + (m^2 - 2k) \frac{1}{2} \cdot \frac{2}{3} + 2mk \frac{1}{2} \cdot \frac{0}{2} + k^2$$

$$E_{out} = \frac{1}{5} + \frac{(m^2 - 2k)}{3} + k^2$$

Agora, os valores de m e k podem ser definidos pelos pontos $(x_1, y_1), (x_2, y_2)$:

$$m = \frac{y_1 - y_2}{x_1 - x_2}$$

$$m = \frac{x_1^2 - x_2^2}{x_1 - x_2}$$

$$m = x_1 + x_2$$

$$k = \frac{x_1 y_2 - y_1 x_2}{x_1 - x_2}$$

$$k = \frac{x_1 x_2^2 - x_1^2 x_2}{x_1 - x_2}$$

$$k = x_1 x_2$$

Logo:

$$E_D[E_{out}] = E_D\left[\frac{1}{5} + \frac{(m^2 - 2k)}{3} + k^2\right]$$

$$E_D[E_{out}] = \frac{1}{5} + \frac{1}{3} E_D[(x_1 + x_2)^2 + 2x_1 x_2] + E_D[x_1^2 x_2^2]$$

$$E_D[E_{out}] = \frac{1}{5} + \frac{1}{3} \cdot \left(\frac{1}{2^2}\right) \cdot \int_{-1}^1 \int_{-1}^1 (x_1^2 + x_2^2 + 4x_1 x_2) dx_1 dx_2 + \left(\frac{1}{2^2}\right) \int_{-1}^1 \int_{-1}^1 x_1^2 x_2^2 dx_1 dx_2$$

$$E_D[E_{out}] = \frac{1}{5} + \frac{1}{3} \cdot \frac{1}{4} \cdot \frac{8}{3} + \frac{1}{4} \cdot \frac{4}{9} = \frac{8}{15}$$

$$bias(x) = (\bar{g}(x) - f(x))^2 = f(x)^2 = x^4$$

$$E_x(bias(x)) = E_x(x^4) = \frac{1}{2} \int_{-1}^1 x^4 dx = \frac{1}{5}$$

Finalmente, sabendo que: $E_{out}(x) = bias(x) + var(x)$

$$\frac{8}{15} = \frac{1}{5} + var(x)$$

$$var(x) = \frac{1}{3}$$

2. Questão 5 da prova.

A partir de uma abordagem Bayesiana, começamos com:

$$P(w|y, X) = \frac{P(w, y|X)}{P(y|X)}$$

Logo, podemos maximizar $P(w, y|X)$:

$$\begin{aligned} \max_w P(w, y|X) &= \max_w P(y|X) P(w|y, X) \\ \hat{w} &= \operatorname{argmax}_w \left[\prod_{n=1}^N \frac{1}{\sigma \sqrt{2\pi}} e^{-\frac{(y_n - (\sum_{i=0}^d w_i x_i))^2}{2\sigma^2}} + \prod_{j=0}^d \frac{1}{\alpha \sqrt{2\pi}} e^{-\frac{w_j^2}{2\alpha^2}} \right] \end{aligned}$$

Aplicando agora a função log (não modifica a lógica da maximização):

$$\begin{aligned} \hat{w} &= \operatorname{argmax}_w \frac{-1}{2\sigma^2} \left[\sum_{n=1}^N (y_n - (w_0 + w_1 x_{n,1} + w_2 x_{n,2} + \dots + w_d x_{n,d}))^2 + \frac{\sigma^2}{\alpha^2} \sum_{j=0}^d w_j^2 \right] \\ \hat{w} &= \operatorname{argmin}_w [(y - Xw)^T (y - Xw) + \frac{\sigma^2}{\alpha^2} w^T w] \\ \hat{w} &= \operatorname{argmin}_w \|y - Xw\|^2 + \lambda \|w\|^2 \end{aligned}$$

Obviamente, o termo no qual chegamos é o mesmo que se encontra na minimização do E_{aug} apresentado.

Dessa forma, fica simples de perceber que a Regressão Ridge, que é basicamente a introdução de um termo de regularização, pode ser interpretada como uma "desvalorização" do conhecimento a priori da distribuição do seu parâmetro w .

A escolha de um λ maior automaticamente resulta em uma escolha de α menor, que se traduz em menor valor de variância do w a priori. Ou seja, 'o que definimos anteriormente como um w parâmetro inicial' ganha mais importância.

Por outro lado, escolher um valor reduzido de λ tem como consequência um aumento em α : nosso w a priori tem variância maior e, por isso, perde importância no resultado do modelo.

Concluimos que o fator adicionado λ pode ser interpretado como uma medição de quão 'bayesiano' você quer ser em seu modelo.